

Sistema Predictivo para la Gestión de Inventarios en una Empresa Farmacéutica utilizando Ciencia de Datos y Aprendizaje Automático

1. INTRODUCCIÓN

1.1 Problema

Las empresas farmacéuticas deben balancear los niveles de medicamentos para poder satisfacer la demanda del mercado. La demanda puede variar por virus estacionarios, promociones, pandemias o eventos epidemiológicos.

La ausencia de herramientas predictivas puede provocar:

- Desabastecimiento de productos.
- Pérdidas por vencimiento de medicamentos.
- Incremento de costos de almacenamiento.
- Disminución de la satisfacción del cliente.

1.2 Objetivo General

Desarrollar un sistema predictivo para apoyar la gestión de inventarios farmacéuticos mediante técnicas de análisis de datos y aprendizaje automático.

1.3 Objetivos Específicos

- Analizar datos históricos de ventas.
- Identificar patrones de consumo.
- Proponer un modelo predictivo.
- Evaluar la utilidad del modelo para la gestión de inventarios.

2. DESCRIPCIÓN DEL CONJUNTO DE DATOS

2.1 Fuente de datos

Conjunto de datos transaccional farmacéutico correspondiente al año 2024.

"C:\Users\carit\Documents\Proyecto_Inventario_Farmaceutico\global_test_set.csv"

2.2 Variables disponibles

Variable	Descripción
Invoice	Número de factura
Barcode	Código de barras
Name	Nombre del medicamento
Dosage_Form	Forma farmacéutica
Sheet	Cantidad de láminas
Sales_Sheet	Cantidad vendida por lámina
Sales_Pack	Cantidad vendida por paquete
adddeddate	Fecha de la transacción
time	Hora
type	Tipo de producto

Tabla 1 Variables del Conjunto de datos

En la tabla se evidencian las variables del Conjunto de datos esto lo resolvimos con el comando df.shape y df. Info()

2.3 Resumen general del Conjunto de datos

Indicador	Valor
Registros	240591
Variables	10
Productos únicos	21870
Fecha inicial	01/01/2024
Fecha final	31/12/2024

Tabla 2. Resumen general del Conjunto de datos

En la tabla se evidencia el numero de registros del Conjunto de datos tomado con el comando df.shape y df. Info() con el cual también pudimos obtener el numero de variables ya que nos presenta el numero de columnas.

Con los comandos df[“name”].nunique() y df[“adddeddate”].min()/ df[“adddeddate”].max() encontramos los productos únicos y las fechas inicial y final.

3.ANALISIS EXPLORATORIO DE DATOS

3.1 Productos más vendidos

Producto	Frecuencia
C%2-A	2489
R.A-C	2055
A.M-E.C	1380

Tabla 3. Productos más vendidos

Se identificaron los productos con mayor frecuencia de venta durante el período analizado. El producto C%2-A registró la mayor cantidad de transacciones con 2489 registros, seguido por R.A-C con 2055 registros. Esta información permite identificar productos de alta rotación y potencialmente críticos para la gestión de inventarios.




Ilustración 1. Top 10 productos más vendidos

La Figura 1 muestra los diez productos con mayor frecuencia de venta dentro del conjunto de datos analizado. El producto C%2-A presenta el mayor número de registros, alcanzando 2489 transacciones, seguido por R.A-C con 2055 registros. Se observa que existe una diferencia significativa entre los primeros productos y el resto, lo que evidencia una concentración de las ventas en un grupo reducido de medicamentos de alta rotación. Esta información resulta relevante para la gestión de inventarios y planificación de abastecimiento.

3.2 Estadísticas Descriptivas

Producto	Promedio
Sheet	2.54
Sales_sheet	2.01
Sales_pack	1.13

Tabla 4. estadísticas descriptivas

Las variables de ventas presentan valores promedio relativamente bajos, indicando que la mayoría de las transacciones corresponden a cantidades reducidas por operación. Sin embargo, existen valores máximos significativamente superiores que sugieren la presencia de compras de mayor volumen.

3.3 Comportamiento Temporal

Se realizó un análisis temporal de las ventas mensuales utilizando la variable "Sales_Sheet". Los resultados muestran una demanda relativamente estable durante el

año 2024, con valores mensuales comprendidos entre 38.894 y 41.085 unidades vendidas. No se identifican patrones estacionales marcados, lo que sugiere un comportamiento homogéneo de la demanda a lo largo del año.

Mes	Ventas totales/ (Sales-sheet)
Enero	39.234
Febrero	28.894
Marzo	40.619
Abril	40.780
Mayo	39.548
Junio	41.085
Julio	38.944
Agosto	40.651
Septiembre	40.459
Octubre	40.385
Noviembre	40.959
Diciembre	40.270

Tabla 5. Ventas Mensuales

Observamos que:

- Las ventas son relativamente estables durante todo el año.
- No existe una estacionalidad fuerte.
- Junio presenta el valor más alto.
- Febrero presenta el valor más bajo.
- La variación entre meses es pequeña.




Ilustración 2. Ventas totales por MES

La Figura 2 muestra el comportamiento mensual de las ventas durante el año 2024. Se observa que la demanda presenta un comportamiento relativamente uniforme a lo largo del período analizado, con valores mensuales cercanos a las 40.000 unidades. No se evidencian patrones estacionales significativos, por lo que la demanda puede considerarse estable durante el año de estudio.

3.4 Clasificación de productos por demanda

Producto	Unidades Vendidas
Voltfast 50mg 30Sachet	4946.0
glufast plus 30 sachrt	4058.0
Disposable Face mask	3741.0
xxxxxxxxxx	3718.0
C%2-A	2642.0
Aspirin Protect 100mg	2550.0
R.A-C	2157.0
Girawa	2034.0
solofine 6	2000.0
sulprim forte 10 tab	1923.0
sulprim forte 10 tab	1923.0

Tabla 6. Top 10 productos por volumen de Ventas

Con el propósito de identificar los productos con mayor impacto en la demanda total, se realizó una agregación de la variable “Sales_Sheet” por producto. Los resultados muestran que Voltfast 50mg 30Sachet registró el mayor volumen de ventas con 4.946 unidades, seguido por Glufast Plus 30 Sachrt con 4.058 unidades y Disposable Face Mask con 3.741 unidades.

Este análisis permite identificar los productos de mayor rotación y relevancia para la planificación de inventarios, priorizando aquellos que requieren un seguimiento más estricto para evitar desabastecimientos.




Ilustración 3. Top 10 Productos por Volumen de Ventas

La Figura 3 presenta los diez productos con mayor volumen de ventas durante el período analizado. Se observa que Voltfast 50 mg 30 Sachet registra la mayor cantidad de unidades vendidas, alcanzando aproximadamente 4.946 unidades, seguido por Glufast Plus 30 Sachrt con 4.058 unidades y Disposable Face Mask con 3.741 unidades.

Los resultados evidencian que un grupo reducido de productos concentra una proporción importante de las ventas totales. Esta información resulta relevante para la gestión de inventarios, ya que permite identificar productos de alta rotación que requieren un monitoreo continuo para evitar problemas de desabastecimiento y optimizar las decisiones de reposición.

3.5 Hallazgos Principales

Del análisis exploratorio realizado sobre el Conjunto de datos farmacéutico se identificaron los siguientes hallazgos:

- El conjunto de datos contiene 240.591 registros correspondientes a transacciones realizadas durante el año 2024.
- Se identificaron 21.870 productos distintos, evidenciando una amplia diversidad de referencias comercializadas.
- Los productos C%2-A, R.A-C y A.M-E.C presentan la mayor frecuencia de aparición en las transacciones.
- Los productos con mayor volumen de ventas son Voltfast 50 mg 30 Sachet, Glufast Plus 30 Sachrt y Disposable Face Mask.
- El comportamiento mensual de las ventas muestra una demanda relativamente estable durante el año, sin patrones estacionales significativos.
- Existe una diferencia entre los productos más frecuentes y los productos con mayor volumen de ventas, lo que indica que la frecuencia de aparición de un producto no necesariamente representa la cantidad total vendida.

4. PROPUESTA DEL MODELO PREDICTIVO PARA GESTION DE INVENTARIOS

4.1 Objetivo del modelo:

El objetivo del modelo predictivo es estimar la demanda futura de productos farmacéuticos utilizando información histórica de ventas registradas durante el año 2024. La predicción permitirá anticipar necesidades de reposición, optimizar los niveles de inventario y reducir costos asociados al desabastecimiento o exceso de stock.

El modelo busca apoyar la toma de decisiones mediante técnicas de aprendizaje automático capaces de identificar patrones de consumo presentes en los datos históricos.

4.2 Variables Utilizadas

Para la construcción del modelo predictivo se consideran las variables disponibles en el Conjunto de datos que presentan relevancia para el comportamiento de la demanda:

Variable	Descripción
Name	Nombre del medicamento
Dosage_Form	Forma farmacéutica
type	Tipo de producto (drug/Supply)
adddate	Fecha de la transacción
Sales_Sheet	Cantidad vendida por lámina
Sales_Pack	Cantidad vendida por paquete

Tabla 7. Variables utilizadas en el modelo

Las variables temporales derivadas de la fecha, como mes y día, pueden utilizarse para identificar patrones de comportamiento de la demanda a lo largo del tiempo.

La variable objetivo-seleccionada para la predicción corresponde a “Sales_Sheet”, debido a que representa directamente el volumen de ventas registrado en cada transacción.

4.3 Modelo Predictivo Seleccionado

El problema planteado corresponde a una tarea de regresión supervisada, debido a que el objetivo consiste en estimar una variable numérica relacionada con la cantidad de productos vendidos.

A partir del análisis exploratorio se observó que la variable “Sales_Sheet” presenta una media de 2,01 unidades por transacción, aunque existen registros con valores significativamente superiores, alcanzando hasta 380 unidades. Esta variabilidad sugiere la presencia de patrones no lineales en los datos.

Por esta razón se propone utilizar el algoritmo de Regresión mediante Bosques Aleatorios como modelo predictivo principal. Este algoritmo pertenece a la familia de los métodos de ensamble y combina múltiples árboles de decisión para generar predicciones más robustas y precisas.

Entre sus principales ventajas se encuentran:

- Capacidad para modelar relaciones no lineales.
- Tolerancia a valores atípicos.
- Bajo riesgo de sobreajuste.
- Facilidad para identificar variables relevantes.
- Buen desempeño en problemas de predicción de demanda.

Debido a estas características, Regresión mediante bosques aleatorios constituye una alternativa adecuada para apoyar la gestión de inventarios farmacéuticos mediante la estimación de ventas futuras.

4.4 Arquitectura Propuesta del Modelo

La arquitectura general propuesta para el sistema predictivo comprende las siguientes etapas:

1. Recolección de datos históricos de ventas.
2. Limpieza y transformación de datos.
3. Generación de variables temporales.
4. Codificación de variables categóricas.
5. División de datos en conjuntos de entrenamiento y prueba.
6. Entrenamiento del modelo de regresión mediante bosques aleatorios
7. Evaluación mediante métricas de desempeño.
8. Generación de predicciones de demanda.
9. Apoyo a la toma de decisiones de inventario.

Este flujo permite transformar los datos históricos almacenados en la base de datos en información útil para la planificación y control de inventarios.



Ilustración 4. Arquitectura propuesta del modelo

La Figura presenta el flujo general del sistema predictivo propuesto. El proceso inicia con la recopilación de datos históricos de ventas, seguido de actividades de limpieza y transformación de datos. Posteriormente se generan variables relevantes para el aprendizaje automático y se entrena un modelo de regresión mediante bosques aleatorios. Finalmente, el sistema produce estimaciones de demanda futura que pueden utilizarse como apoyo para la toma de decisiones relacionadas con abastecimiento, reposición y control de inventarios.

4.5 Métricas de Evaluación

Para evaluar el desempeño del modelo predictivo se proponen métricas comúnmente utilizadas en problemas de regresión:

- MAE (Mean Absolute Error): mide el error promedio absoluto entre los valores reales y predichos.
- RMSE (Root Mean Squared Error): penaliza errores grandes y permite evaluar la precisión global del modelo.
- R^2 (Coeficiente de Determinación): indica qué porcentaje de la variabilidad de los datos es explicado por el modelo.

Métrica	Descripción
MAE	Error absoluto medio
RMSE	Raíz del error cuadrático medio
R^2	Coeficiente de determinación

Tabla 8. Métricas de evaluación propuestas

Estas métricas permitirán cuantificar la capacidad predictiva del sistema antes de su implementación en un entorno real.

4.6 Consideraciones Éticas

El uso de inteligencia artificial en sistemas de gestión de inventarios debe realizarse respetando principios de transparencia y responsabilidad.

Los modelos predictivos constituyen herramientas de apoyo para la toma de decisiones y no deben reemplazar completamente el criterio humano.

Además, es importante garantizar la calidad de los datos utilizados, evitando sesgos derivados de información incompleta o registros erróneos que puedan afectar las predicciones obtenidas.

5. CONCLUSIONES Y RECOMENDACIONES

5.1 Conclusiones:

- a) El análisis exploratorio permitió identificar los productos farmacéuticos con mayor rotación dentro del inventario, destacándose Voltfast 50 mg 30 Sachet como el producto con mayor volumen de ventas.
- b) La demanda mensual presentó un comportamiento relativamente estable durante el año 2024, sin evidenciar patrones estacionales significativos.
- c) Las variables disponibles en el Conjunto de datos permiten plantear un modelo predictivo capaz de estimar la demanda futura de productos farmacéuticos.
- d) El algoritmo de regresión mediante bosques aleatorios constituye una alternativa adecuada debido a su capacidad para modelar relaciones no lineales y manejar grandes volúmenes de información.

5.2 Recomendaciones

- a) Incorporar información de varios años para mejorar la capacidad predictiva del modelo.
- b) Integrar variables externas como campañas promocionales, brotes epidemiológicos y estacionalidad climática.
- c) Implementar el modelo dentro de un sistema de gestión de inventarios para apoyar decisiones operativas.
- d) Realizar procesos periódicos de actualización y reentrenamiento del modelo utilizando nuevos datos de ventas.

6. REFERENCIAS

- [1] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow, O'Reilly Media, 2022.
- [2] J. Han, M. Kamber y J. Pei, Data Mining: Concepts and Techniques, Morgan Kaufmann, 2012.
- [3] Pandas Development Team, Pandas Documentation. Disponible en: <https://pandas.pydata.org>

[4] Scikit-Learn Developers, Scikit-Learn User Guide. Disponible en: <https://scikit-learn.org/>

7. REFLEXIONES ETICAS

La aplicación de técnicas de ciencia de datos y aprendizaje automático en la gestión de inventarios farmacéuticos debe realizarse bajo principios de responsabilidad, transparencia y protección de la información.

Aunque el presente estudio utiliza datos transaccionales sin información personal de pacientes, es importante garantizar que cualquier sistema implementado preserve la confidencialidad y seguridad de los datos utilizados.

Los modelos predictivos constituyen herramientas de apoyo para la toma de decisiones, pero no deben sustituir completamente el criterio humano.

Las predicciones generadas pueden verse afectadas por cambios inesperados en el mercado, emergencias sanitarias, pandemias o modificaciones en los patrones de consumo, por lo que los resultados deben ser interpretados por personal capacitado.

Asimismo, es necesario mantener mecanismos de monitoreo y actualización periódica del modelo para evitar degradación en su desempeño y garantizar que las decisiones de abastecimiento se basen en información confiable y actualizada.

Finalmente, el uso responsable de la inteligencia artificial en el sector farmacéutico puede contribuir a mejorar la disponibilidad de medicamentos, reducir pérdidas por vencimiento y optimizar los recursos de la organización, generando beneficios tanto para la empresa como para los usuarios finales.